

# 首次公开！深度学习在知识图谱构建中的应用

原创 2018-03-15 游维 阿里技术



阿里妹导读：在智能化时代的今天，搜索引擎不仅能理解用户检索的信息、并总结出与搜索话题相关的内容，更在逐步构建一个与搜索结果相关的完整知识体系，让用户获得意想不到的发现。神马搜索的知识图谱与应用团队就在这条路上不断探索中。

昨天，我们介绍了基于DeepDive的关系抽取方法及其在知识图谱数据构建中应用（传送门：[知识图谱数据构建的“硬骨头”，阿里工程师如何拿下？](#)）。这个方法准确率高、交互好，在单一关系的抽取任务中体现了强大的能力。今天，我们将为大家继续分享，基于深度学习的关系抽取技术及其在神马知识图谱数据构建中的探索和实践，以及业务落地过程中遇到的一些挑战，期待与大家一起交流探讨。

## 深度学习模型介绍

DeepDive系统在数据处理阶段很大程度上依赖于NLP工具，如果NLP的过程中存在错误，这些错误将会在后续的标注和学习步骤中被不断传播放大，影响最终的关系抽取效果。为了避免这种传播和

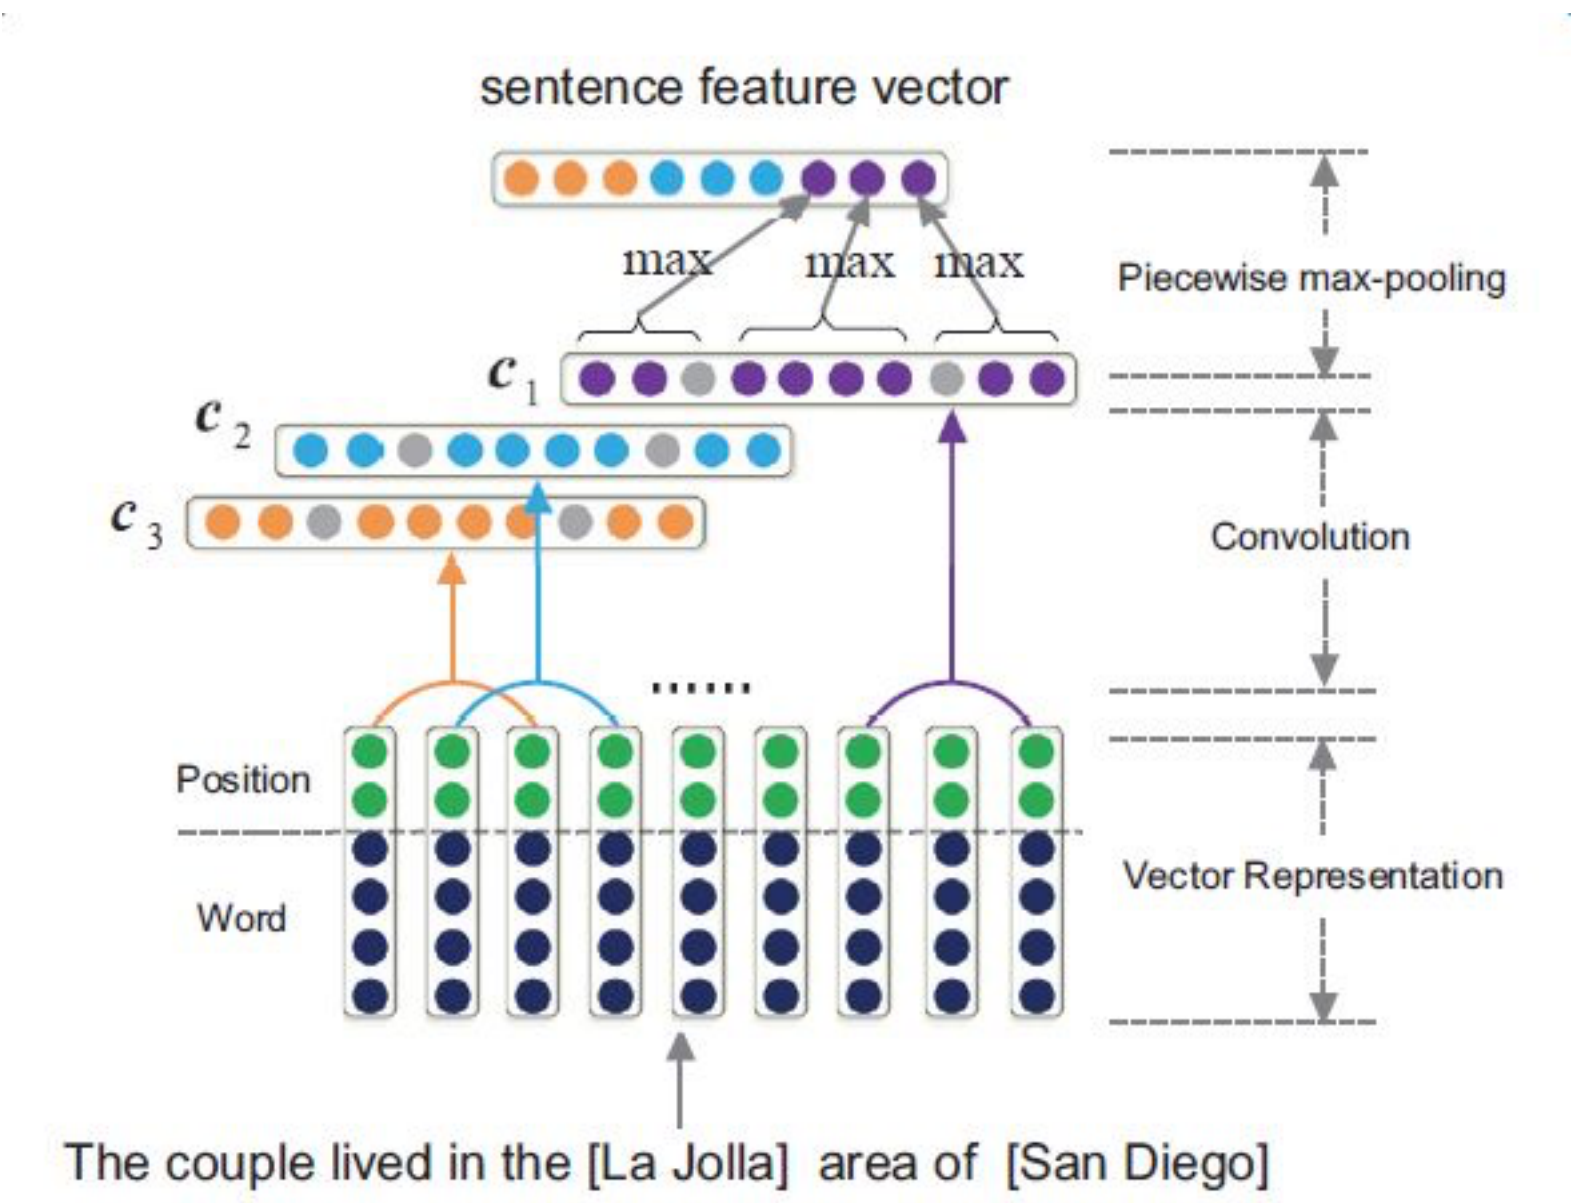
影响，近年来深度学习技术开始越来越多地在关系抽取任务中得到重视和应用。本章主要介绍一种远程监督标注与基于卷积神经网络的模型相结合的关系抽取方法以及该方法的一些改进技术。

### Piecewise Convolutional Neural Networks (PCNNs) 模型

PCNNs模型由Zeng et al.于2015提出，主要针对两个问题提出解决方案：

- 针对远程监督的wrong label problem，该模型提出采用多示例学习的方式从训练集中抽取置信度高的训练样例训练模型。
- 针对传统统计模型特征抽取过程中出现的错误和后续的错误传播问题，该模型提出用piecewise的卷积神经网络自动学习特征，从而避免了复杂的NLP过程。

下图是PCNNs的模型示意图：



PCNNs模型主要包括以下几个步骤：



- **向量表示**：该步骤采用word embedding和position embedding相结合的方法将token转化为低维的向量，注意这里的token是以实体为单位的。Word embedding采用的是word2vec的skip-gram模型。考虑到实体在句子中位置的重要性，向量的表示还采用了position embedding，它的定义是句中每个token到E1和E2的相对距离。如图中的area这个token，到E1和E2距离分别为1和-2，position向量就是 $[1, -2]$ 。Word2vec向量和position向量拼接起来，将一个sentence表示为一个  $d \times |S|$  的矩阵，其中  $|S|$  是sentence包含的token数， $d$  是token向量表示的长度， $d = k_w + 2k_d$ ， $k_w$  是word2vec的向量长度， $k_d$  是position向量长度。



- **卷积**：向量表示得到的结果  $S = s_1, s_2, \dots, s_{|S|}$  传给卷积层，其中  $s_i$  是第  $i$  个token的向量表示。在卷积层，我们构造一个权重矩阵  $W$  作为卷积核，则有  $W \in R^{\omega \times k}$ ，在上面的模型示意图中  $\omega = 3$ 。给定一个卷积核，随滑动窗口作点乘，得到一个  $c_j = W \otimes S_{(j-\omega+1):j}$ ，其中  $1 \leq j \leq |S| - \omega + 1$ 。当有  $n$  个卷积核时，得到  $c_{ij} = W_i \otimes S_{(j-\omega+1):j}$ ，其中  $1 \leq i \leq n$  且  $1 \leq j \leq |S| - \omega + 1$ 。
- **池化**：卷积完成后，将输出传给池化层，PCNNs模型采用的是max pooling，但是对普通的single max pooling作了改进，称为piecewise max-pooling。Piecewise的考虑是将一个sentence按照E1，E2的所在位置切为3段，对每段分别作max pooling，其目的是为了更好的捕获两个实体间的结构化信息。对于卷积的结果向量  $c_i$ ，切成三段后有  $c_i = c_{i1}, c_{i2}, c_{i3}$ ，max pooling求得  $p_{ij} = \max(c_{ij})$ ，其中  $1 \leq i \leq n$  且  $1 \leq j \leq 3$ 。对于每个句子  $S$ ，池化层输出为特征向量  $b_S = \tanh(p)$ 。
- **Softmax分类输出**：池化的结果向量传给softmax层，通过 softmax 分类器计算分到每个类目（一个类目代表一种关系）的置信度。
- **多示例学习**：核心思想是通过多示例学习的方法选取每个包中置信度最高的样例作为正样例进行训练，具体算法见论文[2]。在训练阶段，目标函数定义如下，其中  $y_i$  表示的是关系类别， $m_i^j$  表示的是第  $i$  个包中的第  $j$  个样例， $q_i$  是每个包中包含的样例个数。

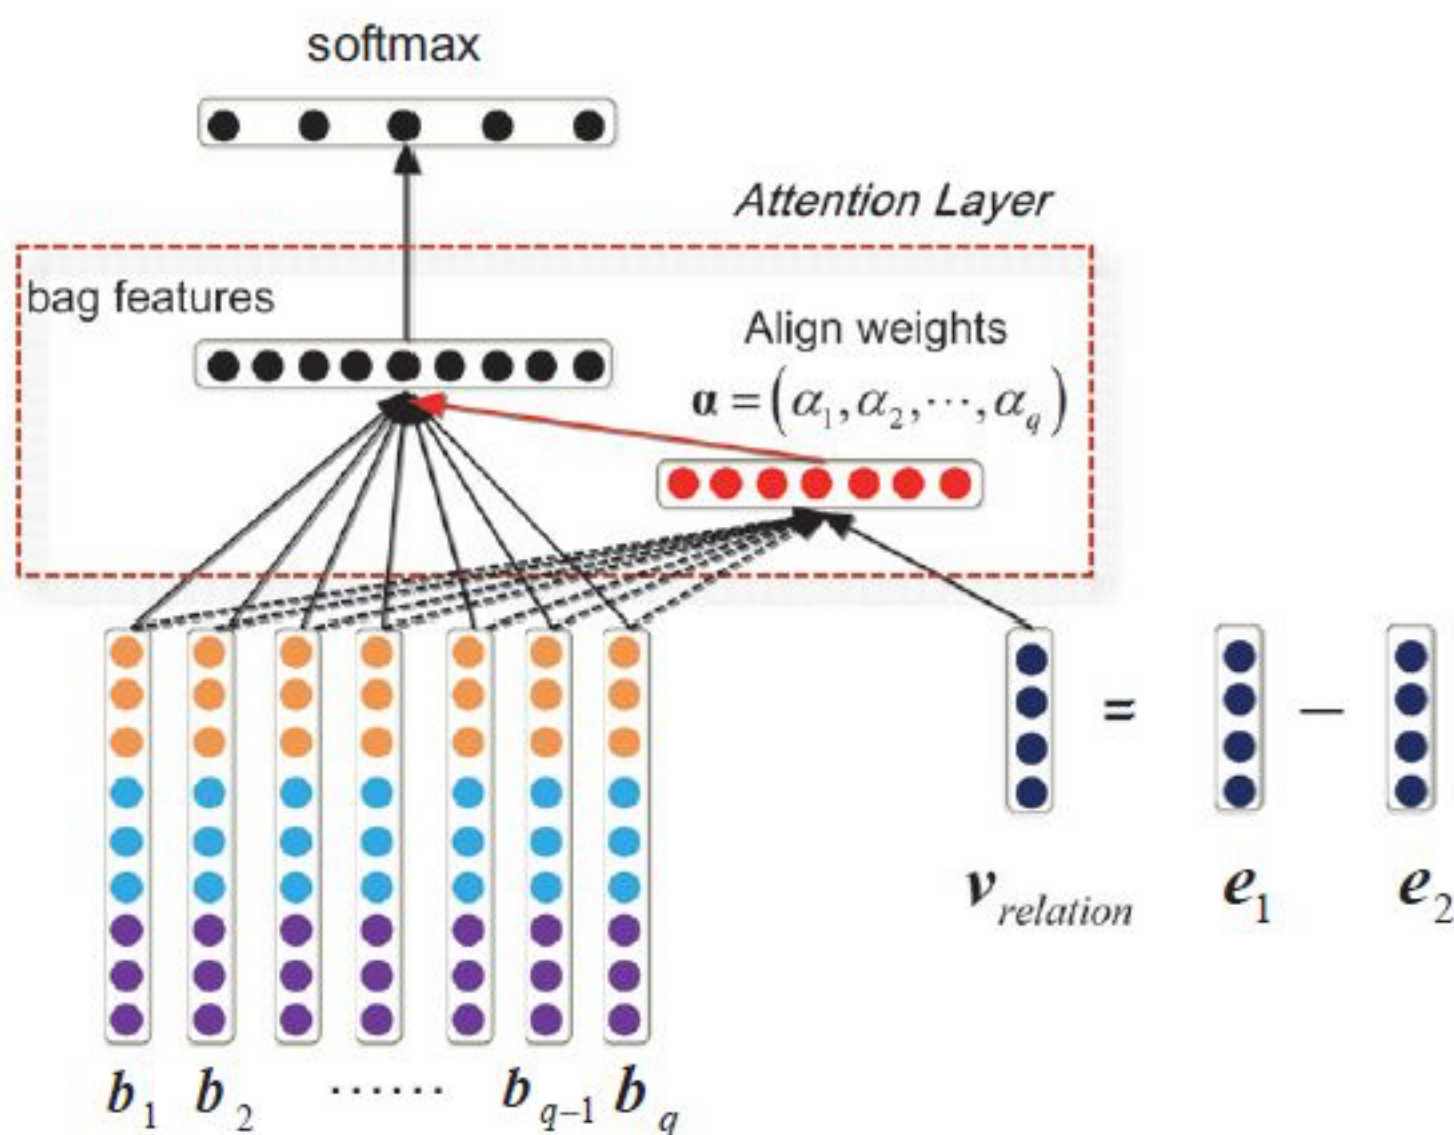
$$J(\theta) = \sum_{i=1}^T \log p(y_i | m_i^j; \theta)$$

$$j^* = \arg \max_j p(y_i | m_i^j; \theta) \quad 1 \leq j \leq q_i$$

实验证明，PCNNs + 多实例学习的方法 Top N 上平均值比单纯使用多示例学习的方法高了 5 个百分点。

## Attention机制和其它改进

上述模型对于每个实体对只选用一个句子进行学习和预测，损失了大量的来自其它正确标注句子的信息。为了在滤除wrong label case的同时，能更有效地利用尽量多的正确标注的句子，Lin et al. 于 2016 年提出了 PCNNs+Attention (APCNNs) 算法。相比之前的 PCNNs 模型，该算法在池化层之后，softmax 层之前加入了一种基于句子级别的 attention 机制，算法的示意图如下：



图中  $b_1, b_2, \dots, b_q$  是一个包中的所有instance，其中每个  $b_i$  都是池化层输出的一个句向量。我们用这个包对应的两个实体的向量差来构造关系向量，即  $v_{relation} = e_1 - e_2$ ，其中  $e_1$  和  $e_2$  是word2vec生成的实体向量。对于每个  $b_i$ ，计算其与  $v_{relation}$  的相似度，得到  $\alpha_i$  作为该句子的权重：




$$\alpha_i = \frac{\exp(\omega_i)}{\sum_{j=1}^q \exp(\omega_j)}$$

$$\omega_i = \mathbf{W}_a^\top (\tanh[b_i; v_{relation}]) + b_a$$

其中  $[b_i; v_{relation}]$  表示向量的拼接， $b_a$  为补偿值。 $b_i$  的加权将作为包向量输出给 softmax 层。Attention 机制的应用能够根据特定关系为实体对的每个句子分配权重，通过不断学习能够使得有效句子获得较高的权重，有噪音的句子获得较小的权重。

除了 Attention 机制外，还有一些其它的辅助信息也被加入多示例学习模型来改关系抽取的质量，例如在计算实体向量的时候加入实体的描述信息（Ji et al., 2017）；利用外部神经网络获取数据的可靠性和采样的置信度等信息对模型的训练进行指导（Tang et al., 2017）。

下图显示了各模型和改进算法的准确率和召回率的对比，其中 Mintz 不对远程监督的 wrong label problem 做处理，直接用所有标注样例进行训练；MultiR 和 MIML 是采用概率图模型进行示例筛选的两种多示例学习模型；PCNN+MIL 是本章第一小节介绍的模型；APCNNs 在 PCNN+MIL 基础上添加了 attention 机制；PCNNs+D 在 PCNN+MIL 基础上添加了对描述信息的使用；APCNNs+D 在 APCNNs 基础上添加了对描述信息的使用。实验采用的是该领域评测中使用较广泛的 New York Times (NYT) 数据集（Riedel et al., 2010）。



深度学习模型在神马知识图谱数据构建中的应用目前还处于探索阶段，本章将介绍当前的工作进展和业务落地过程中遇到的一些问题。

### 语料准备和实体向量化

深度学习模型较大程度依赖于token向量化的准确性。与基于DeepDive方法的语料准备相同，这里的token切分由以词为单位，改为以实体为单位，以NER环节识别的实体粒度为准。Word2vec生成的向量表征token的能力与语料的全面性和语料的规模都很相关，因此我们选择百科全量语料作为word2vec的训练语料，各统计数据 and 模型参数设置如下表所示：

语料选择	百科全量语料，根据 title 和 article 内容匹配去重
Article 数量	2850w
切分的 Sentence 数量	12.6 亿（切分时每个 sentence 的中文字符上限设为 200）
NER 处理时长	约 5000qps
Word2vec 模型	skip-gram
Word2vec 参数	size = 100, windows = 5, min_count = 6
Word2vec 得到的总 token 数	320w

为了验证词向量训练的效果，我们对word2vec的结果做了多种测试，这里给出部分实验数据。下图所示的是给定一个实体，查找最相关实体的实验：

刘德华	阿里巴巴	清华大学
谢霆锋 0.904822587967	阿里巴巴集团 0.761922121048	上海交通大学 0.858610630035
郭富城 0.900676131248	电商 0.750814378262	北京理工大学 0.835810422897
梁朝伟 0.887233674526	马云 0.75007212162	浙江大学 0.834890067577
张国荣 0.877490222454	京东商城 0.738155841827	同济大学 0.827325940132
任贤齐 0.866412222385	ebay 0.735245704651	北京大学 0.822968542576
郑伊健 0.862187683582	天猫 0.717967033386	北京航空航天大学 0.821932733059
陈小春 0.855975866318	58 同城 0.712087988853	东南大学 0.820223033428
谭咏麟 0.845089614391	雅虎 0.708898603916	华中科技大学 0.819050967693
郑中基 0.841713488102	携程 0.707009911537	天津大学 0.802386701107
古巨基 0.840413093567	网商 0.704675614834	南开大学 0.793739020824

以下是给定一个实体对和预测实体对的其中一个实体，计算预测实体对中另一个实体的实验。随机


选取了五种预测关系，构造了15组给定实体对和预测实体对，预测结果如下图所示，除了飘红的两个例子，其余预测均正确：

关系	输入		输出	
	给定实体对（E1，E2） E1、E2 均为输入	预测实体对（E3，E4） E3 为输入，E4 为输出		
机构-高管	阿里巴巴	马云	百度	李彦宏
	刘强东	京东	马云	阿里巴巴
国家-首都	开罗	埃及	巴黎	法国
	中国	北京	日本	东京
人物	诸葛亮	黄月英	刘备	孙尚香
	钱钟书	杨绛	梁思成	林洙
	司马懿	司马昭	曹操	曹丕
	杨幂	刘恺威	孙俪	马雅舒
	王菲	窦靖童	杨幂	宋茜
	曹植	曹丕	司马昭	司马师
常识	柳树	植物	狗	动物
	哈士奇	狗	波斯猫	猫
	可乐	饮料	蛋糕	糕点
影视	断背山	电影	李安	制片人
	李安	导演	刘德华	演员

### 模型选取与训练数据准备

具体应用中我们选择采用APCNNs模型。我们在NYT标准数据集上复现了上一章提到的几种关键模型，包括CNN+MIL，PCNN+MIL，CNNs（基于Attention机制的CNN模型）和APCNNs。复现结果与论文中给出的baseline基本一致，APCNNs模型的表现明显优于其它模型。下图是几种模型的准召结果对比：





为了得到丰富的训练数据，我们取知识图谱中建设相对完善的人物、地理位置、组织机构、电影、电视、图书等领域下的15个核心关系，如电影演员、图书作者、公司高管、人物出生地等，对照百科全量语料，产出relation值为15个关系之一的标注正例，合计数目在千万量级，产出无relation值标注（relation值为NA）的示例超过1亿。

E1_id	E2_id	E1	E2	Relation	Sentence (按 token 切分)
per_1f67c50c	per_4ae55cb4	王贲	王翦	/person/parents_children	公元 前 225 年，秦始皇 派 王翦 的 儿子 王贲 率领 10 万 大军 去 攻打 魏国
per_03e72ebe	per_8de509fc	任容萱	任家萱	/person/sibling	该 片 是 任容萱 在 内地 的 首部 大 荧幕 作品，由于 姐姐 任家萱 在 内地 拍摄 电视剧 时 严重 受伤，因此 这次 任容萱 来到 内地 拍戏，让 全 家人 格外 关切，在 拍戏 的 时候 都 有 妈妈 陪伴
tv_064ed070	per_e52f40ca	爱上琉璃苣女孩	陈乔恩	/tv/regular_tv_appearance	《 命中注定我爱你 》( 又 名 《 爱上琉璃苣女孩 》)，是 陈乔恩、阮经天、陈楚河、白歆惠 等 主演 的 台湾 偶像剧，由 陈铭章 执导，台湾 三立 电视 制作
per_ac3fcd98	loc_c0ff9988	寸待龙	腾冲县	/person/place_of_birth	寸待龙，男，汉族，1960 年 6 月 出生，云南 腾冲县 人
film_42a39436	per_4d1652fc	定军山	谭鑫培	/film/performance	1905 年，单独 出演 中国 第一 部 电影 《 定军山 》的 武汉 人 谭鑫培 是 中国 第一个 电影 演员

## 应用尝试和问题分析



我们进行了两组实验：一组是基于所有提取的15种核心关系的较大规模的实验。在这组实验中，我们随机从上节生成的数据集中随机抽取了200万作为训练数据，另外随机抽取100万作为测试数据。使用的参数为：词向量维数  $k_w = 50$ ，position向量维数  $k_d = 5$ ，窗口大小  $\omega = 3$ ，卷积核数  $n = 230$ ，batch size  $B = 150$ ，learning rate  $\lambda = 0.01$ ，dropout rate  $p = 0.5$ 。实验运行时间约3天，得到precision为0.73时，recall值为0.0091，部分运行结果截图如下：

0.999480	林熙蕾 杨晨 /person/spouses
0.999456	药师丸博子 玉置浩二 /person/spouses
0.999435	贾静雯 孙志浩 /person/spouses
0.999434	杜预 杜恕 /person/parents_children
0.999426	乐基儿 黎明 /person/spouses
0.999423	马雅舒 吴奇隆 /person/spouses
0.999423	钟镇涛 章小蕙 /person/spouses
0.999413	邓伟杰 唐宁 /person/spouses
0.999410	王菲 李亚鹏 /person/spouses
0.999395	陆绩 陆郁生 /person/parents_children
0.999386	尔冬升 尔光 /person/parents_children
0.999383	狄知逊 狄孝绪 /person/parents_children
0.999379	司马池 司马光 /person/parents_children
0.999368	严铮 钟丽缇 /person/spouses
0.999367	赵锦焘 梁又琳 /person/spouses
0.999354	朱娜 沙宝亮 /person/spouses
0.999351	白百何 陈羽凡 /person/spouses
0.999349	刘芸 郑钧 /person/spouses
0.999338	关颖 朱志威 /person/spouses
0.999304	钟镇涛 范姜 /person/spouses
0.999284	孙俪 邓超 /person/spouses
0.999272	张定涵 王志飞 /person/spouses



另一组实验是基于特定relation集合的小规模实验，选取了三种特定的人物关系：夫妻、父母-子女、兄弟姐妹。小规模实验运行时间较短，方便进行调参。参数调整的取值范围如下：词向量维数  $k_w$  取值  $\{50, 100, 150, 200\}$ ，position向量维数  $k_d$  取值  $\{5, 10, 15\}$ ，窗口大小  $\omega$  取值  $\{3, 4, 5, 6, 7\}$  卷积核数  $n$  取值  $\{50, 100, 150, 200, 230\}$ ，batch size  $B$  取值  $\{50, 100, 150, 200\}$ ，learning rate  $\lambda$  取值  $\{0.1, 0.01, 0.001\}$ ，参数最终取值为：词向量维数  $k_w = 100$ ，position向量维数  $k_d = 5$ ，窗口大小  $\omega = 3$ ，卷积核数  $n = 200$ ，batch size  $B = 100$ ，learning rate  $\lambda = 0.01$ ，dropout rate  $p = 0.5$ 。实验的部分输出结果对比如下图所示，所有迭代完成后，得到precision为0.83的情况下，recall为0.37：

1	<b>0.99966</b>	<b>王菲</b>	<b>窦唯</b>	<b>/person/spouses</b>	
2	0.73251	王菲	窦唯	/person/parents_children	
3	0.478892	王菲	窦唯	/person/sibling	
4	<b>0.99941</b>	<b>王菲</b>	<b>李亚鹏</b>	<b>/person/spouses</b>	
5	0.689352	王菲	李亚鹏	/person/parents_children	
6	0.337659	王菲	李亚鹏	/person/sibling	
7	<b>0.99459</b>	<b>王菲</b>	<b>王佑林</b>	<b>/person/parents_children</b>	
8	0.829076	王菲	王佑林	/person/sibling	
9	0.339752	王菲	王佑林	/person/spouses	
10	<b>0.98818</b>	<b>王菲</b>	<b>夏桂影</b>	<b>/person/parents_children</b>	
11	0.801718	王菲	夏桂影	/person/sibling	
12	0.642479	王菲	夏桂影	/person/spouses	
13	<b>0.98066</b>	<b>王菲</b>	<b>窦靖童</b>	<b>/person/parents_children</b>	
14	0.591788	王菲	窦靖童	/person/sibling	
15	0.421908	王菲	窦靖童	/person/spouses	
16	<b>0.98791</b>	<b>王菲</b>	<b>李嫣</b>	<b>/person/parents_children</b>	
17	0.557504	王菲	李嫣	/person/spouses	
18	0.483526	王菲	李嫣	/person/sibling	

APCNNs模型在辅助知识图谱数据构建中目前还处于尝试阶段。就运算能力而言，APCNNs模型相比DeepDive系统更有优势，能在大规模语料上同时针对多个关系进行计算，且迭代更新过程无需人工校验交互。但在业务落地过程中，我们也遇到了一些问题，总结如下：

- 大规模实验耗时过长，给参数的调整和每一次算法策略上的迭代增加了难度



- 目前学术界通用的测试语料是英文的NYT数据集，相同的模型应用于中文语料时，存在准召率对标困难的问题
- 深度学习的过程人工难以干预。假设我们要预测（杨幂，刘恺威）的婚姻关系，但从最初的基于大规模语料的词向量生成开始，如果该语料中（杨幂，刘恺威）共现时的主导关系就不是婚姻关系，而是影视剧中的合作关系（如“该片讲述杨幂饰演的夏晚晴在遭遇好友算计、男友婚变的窘境下，被刘恺威饰演的花花公子乔津帆解救，但却由此陷入更大圈套的故事。”），或基于某些活动的共同出席关系（如“杨幂与刘恺威共同担任了新浪厦门爱心图书馆的公益大使”），则在attention步骤中得到的关系向量就会偏向合作关系，这将导致计算包中每个句子的权值时，表达婚姻关系的句子难以获得高分，从而导致后续学习中的偏差。
- 深度学习模型的结果较难进行人工评测，尤其对于知识图谱中没有出现的实体对，需要在大规模的中间过程矩阵中进行匹配和提取，将权重矩阵可视化为包中每个句子的得分，对计算资源和人工都有不小的消耗。

## 总结与展望

基于DeepDive的方法和基于深度学习的方法各有优势和缺陷，以下从4个方面对这两种方法进行总结和对比：

### 1、语料的选取和范围

- Deepdive可适用于较小型、比较专门的语料，例如历史人物的关系挖掘；可以针对语料和抽取关系的特点进行调整规则，如婚姻关系的一对一或一对多，如偏文言文的语料的用语习惯等。
- APCNNs模型适用于大规模语料，因为attention机制能正常运行的前提是word2vec学习到的实体向量比较丰富全面。

### 2、关系抽取

- Deepdive仅适用于单一关系的判断，分类结果为实体对间某一关系成立的期望值。针对不同的关系，可以运营不同的规则，通过基于规则的标注能较好地提升训练集的标注准确率。
- APCNNs模型适用于多分类问题，分类结果为relation集合中的关系得分排序。无需针对relation集合中特定的某个关系做规则运营。

### 3、长尾数据

- Deepdive更适用于长尾数据的关系挖掘，只要是NER能识别出的实体对，即使出现频率很低，也能根据该实体对的上下文特征做出判断。
- APCNNs模型需要保证实体在语料中出现的次数高于一定的阈值，如 $\text{min\_count} \geq 5$ ，才能保证该实体有word2vec的向量表示。bag中有一定数量的sentence，便于选取相似度高的用于训练

### 4、结果生成与检测

- Deepdive对输出结果正误的判断仅针对单个句子，同样的实体对出现在不同的句子中可能给出

完全不同的预测结果。测试需要结合原句判断结果是否准确，好处是有原句作为依据，方便进行人工验证。

- APCNNs模型针对特定的实体对做判断，对于给定的实体对，系统给出一致的输出结果。对于新数据的结果正确性判断，需要结合中间结果，对包中被选取的句子集合进行提取和验证，增加了人工检验有的难度。

在未来的工作中，对于基于DeepDive的方法，我们在扩大抓取关系数目的同时，考虑将业务实践中沉淀的改进算法流程化、平台化，同时构建辅助的信息增补工具，帮助减轻DeepDive生成结果写入知识图谱过程中的人工检验工作，例如，对于婚姻关系的实体对，我们可以从图谱获取人物的性别、出生年月等信息，来辅助关系的正误判断。

对于基于深度学习的方法，我们将投入更多的时间和精力，尝试从以下几方面促进业务的落地和模型的改进：

- 将已被DeepDive证明有效的某些改进算法应用到深度学习方法中，例如根据关系相关的关键词进行过滤，缩小数据规模，提高运行效率。
- 将计算中间结果可视化，分析attention过程中关系向量与sentence选取的关联，尝试建立选取结果好坏的评判机制，尝试利用更丰富的信息获得更准确的关系向量。
- 考虑如何突破预先设定的关系集合的限制，面向开放领域进行关系抽取，自动发现新的关系和知识。
- 探索除了文本以外其它形式数据的关系抽取，如表格、音频、图像等。

## 参考文献

- [1]. 林衍凯、刘知远，基于深度学习的关系抽取
- [2]. Daojian Zeng, Kang Liu, Yubo Chen, and Jun Zhao. 2015. Distant Supervision for Relation Extraction via Piecewise Convolutional Neural Networks. In EMNLP. 1753–1762.
- [3]. Guoliang Ji, Kang Liu, Shizhu He, Jun Zhao. 2017. Distant Supervision for Relation Extraction with Sentence-Level Attention and Entity Descriptions. Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence
- [4]. Siliang Tang, Jinjian Zhang, Ning Zhang, Fei Wu, Jun Xiao, Yueting Zhuang. 2017. ENCORE: External Neural Constraints Regularized Distant Supervision for Relation Extraction. SIGIR'17
- [5]. Zeng, D.; Liu, K.; Chen, Y.; and Zhao, J. 2015. Distant supervision for relation extraction via piecewise convolutional neural networks. EMNLP.
- [6]. Riedel, S.; Yao, L.; and McCallum, A. 2010. Modeling relations and their mentions without labeled text. In Machine Learning and Knowledge Discovery in Databases. Springer. 148–163.
- [7]. Ce Zhang. 2015. DeepDive: A Data Management System for Automatic Knowledge Base Construction. PhD thesis.
- [8]. Hoffmann, R.; Zhang, C.; Ling, X.; Zettlemoyer, L.; and Weld, D. S. 2011. Knowledge-based weak supervision for



information extraction of overlapping relations. In Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies–Volume 1, 541–550. Association for Computational Linguistics.

[9]. Surdeanu, M.; Tibshirani, J.; Nallapati, R.; and Manning, C. D. 2012. Multi-instance multi-label learning for relation extraction. In Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning, 455–465. Association for Computational Linguistics.

[10]. Shingo Takamatsu, Issei Sato and Hiroshi Nakagawa. 2012. Reducing Wrong Labels in Distant Supervision for Relation Extraction. Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics, pages 721–729

[11]. Zeng, D.; Liu, K.; Lai, S.; Zhou, G.; Zhao, J.; et al. 2014. Relation classification via convolutional deep neural network. In COLING, 2335–2344.

[12]. Ce zhang, Cheistopher Re; et al. 2017. Communications of the ACM CACM Homepage archive  
Volume 60 Issue 5, Pages 93-102

[13]. Mintz, M.; Bills, S.; Snow, R.; and Jurafsky, D. 2009. Distant supervision for relation extraction without labeled data. In Proceedings of the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing of the AFNLP: Volume 2, 1003–1011. Association for Computational Linguistics.

[14]. <http://deepdive.stanford.edu/>

----- End -----

你可能还喜欢

点击下方图片即可阅读



知识图谱数据构建的“硬骨头”，  
阿里工程师如何拿下？





如何用架构师思维解读区块链技术？



十年前，他如何自学技术进阿里？



关注「**阿里技术**」  
把握前沿技术脉搏